Sistema Inteligente Basado en Visión por Computador para la Detección Automática de Accidentes

Entregable 1: Propuesta y Estado del Arte

Borrador — Semana 5

Materia: Ciencias de la Computación

Jorel Sebastian Vargas Ibarra · Juan David Polanco Ortiz · Omar Gabriel Viana Sepulveda

Universidad Surcolombiana / Ingeniería de software

Resumen

Cada año se registran alrededor del mundo cerca 1,19 millones de muertes a causa de siniestros viales, lo que convierte a los accidentes de tránsito en la principal causa de muerte en personas de entre 5 y 29 años [1]. A este problema se suma la congestión vehicular creciente en las ciudades, que incrementa en gran medida los tiempos de desplazamiento, el consumo de combustible y también las emisiones contaminantes.

En los últimos años, los avances de visión por computadora, aprendizaje profundo y aprendizaje por refuerzo has permitido el desarrollo de sistemas capaces de analizar en tiempo real el flujo a partir de cámaras de videovigilancia, tanto para la parte de la optimización de semáforos como para detectar de forma automatizada accidentes viales [2]-[9], [15]-[18].

El presente documento plantea un proyecto que propone el diseño y desarrollo de un sistema inteligente integrado que combine (i) un módulo de detección automática de accidentes vehiculares basado en modelo de detección de objetos de la familia YOLO entrenado sobre un conjunto de datos de al menos 35.000 imágenes, (ii) un módulo de optimización inteligente de tráfico apoyado en técnicas de aprendizaje automático, y (iii) un módulo de notificación que permita dar aviso a las entidades de atención a emergencias para proporcionar información sobre el accidente ocurrido, su gravedad y ubicación.

Palabras clave: optimización de tráfico, detección de accidentes, visión por computadora, aprendizaje automático, YOLO, internet de las cosas, sistemas de transporte inteligente.

1. Introducción

La movilidad urbana hoy en día enfrenta dos retos estrechamente relacionados: la congestión de tráfico vehicular y la siniestralidad vial. De acuerdo con el informe sobre la

Situación Mundial de la Seguridad Vial 2023 de la Organización Mundial de la Salud, aunque las muertes por accidentes de tránsito se redujeron un 5% entre 2010 y 2021, la cifra anual continua en 1,19 millones de personas, con mas de 3.200 fallecimientos diarios, y estos siniestros siguen siendo la principal causa de muerte en niños y jóvenes de 5 a 29 años; además de eso, nueve de cada diez de estas muertes ocurren en países de ingresos bajos y medios [1]. En paralelo, el constante crecimiento del sector automotor y la urbanización han intensificado la congestión vehicular, generando pérdidas económicas significativas, mayor contaminación y una respuesta mucho más lenta de los servicios de emergencia ante incidentes de esta índole.

Frente a este panorama la convergencia de la inteligencia artificial (IA), el aprendizaje profundo (Deep learning) y el internet de las cosas (IoT) han abierto nuevas posibilidades para llevar a cabo una transformación de los sistemas de tránsito tradicionales en Sistemas de Transporte Inteligente con la capacidad de percibir, analizar y tomar acción sobre el entorno vial en tiempo real [10]-[14], [19]. En los cuales, por un lado, los modelos de detección de objetos basados en redes neuronales convolucionales en particular la familia de arquitecturas YOLO (You Only Look Once)- han demostrado un destacado desempeño para la identificación de vehículos, la clasificación de su comportamiento y el reconocimiento de patrones asociados a colisiones a partir de videos de cámaras de vigilancia urbanas [3]-[9]. Por otro lado, las técnicas de aprendizaje por refuerzo profundo (Deep Reinforcement Learning) han sido aplicadas de manera exitosa al control adaptativo de semáforos, logrando importantes reducciones en los tiempos de espera, la congestión y las emisiones vehiculares en comparación con esquemas de temporización fija [15]-[18], [20].

A pesar de estos evidentes e importantes avances en el área del transporte, las investigaciones revisadas evidencian que la mayoría de los desarrollos abordan la detección de accidentes y la optimización del flujo vehicular como problemas aislados el uno del otro, entrenados y evaluados sobre conjuntos de datos y arquitecturas completamente distintas, lo que puede llegar a suponer una limitación en su acoplamiento en una plataforma central que aproveche la misma infraestructura de cámaras y cómputo para ambos fines [5]-[7], [10].

En este contexto, el presente proyecto plantea el diseño y desarrollo de un sistema inteligente que integre en una misma solución la optimización de tráfico y la detección temprana de accidentes vehiculares, entrenado sobre un conjunto de datos de imágenes de tránsito urbano bajo diferentes escenarios y situaciones.

2. Formulación del problema de investigación

2.1 Planteamiento del problema

Los sistemas de gestión de tráfico implementados en la mayoría de ciudades aún dependen en gran medida de revisión constante y manual de cámaras de videovigilancia para el monitoreo del flujo vehicular y los accidentes de tráfico. Este modelo tiene limitaciones claras: (i) no permite analizar profundamente las variaciones del tráfico como los cambios en la densidad y la composición vehicular en el transcurso del día, dificultando la identificación de patrones de congestión; (ii) depende casi exclusivamente de la supervisión de un operador o civil humano para la identificación de un accidente de tráfico, retrasando la notificación a los servicios de emergencia agravando las consecuencias del siniestro [10], [12], [13].

Ante el creciente volumen de video generado por las infraestructuras urbanas (cámaras de seguridad, tráfico y monitoreo) , resulta muy necesario transitar hacia sistemas automatizados basados en Visión por Computadora (Computer Vision). Estos sistemas deben tener la capacidad de analizar indicadores de tráfico en tiempo real, integrando y cruzando la información para detectar accidentes de forma temprana y precisa, notificando a los servicios de emergencia la ubicación del siniestro y mitigando el impacto en la movilidad urbana.

2.2 Preguntas de investigación

A partir del planteamiento anterior, el proyecto busca responder la siguiente pregunta:

¿Cuál es la efectividad de un sistema de Computer Vision para detectar accidentes de tráfico urbano basándose en el análisis en tiempo real de la densidad, la composición vehicular y los niveles de congestión?

2.3 Objetivos

Objetivo general

Diseñar y desarrollar un sistema inteligente basado en Computer Vision que permita la detección automática de accidentes de tránsito a partir de videovigilancia urbana.

Objetivos específicos:

- Construir un conjunto de datos de mínimo 35.000 imágenes con el propósito del entrenamiento de un modelo de detección de accidentes.
- Diseñar, entrenar y evaluar un modelo de detección de objetos basado en la familia YOLO que permita la identificación y clasificación de vehículos y eventos de colisión.
- Implementar un módulo que permita la notificación de incidentes de tránsito a los servicios de emergencia.
- Integrar el modelo en un prototipo funcional y evaluar su desempeño mediantes métricas estándar de detección de objetos (precisión, exhaustividad, F1-score, mAP) y de eficiencia.
- Documentar los resultados obtenidos en un artículo científico siguiendo el formato IEEE.

2.4 Justificación e innovación

El presente proyecto se tiene como justificación la magnitud del problema de la siniestralidad vial a nivel global [1] y por la evidencia de que las soluciones implementadas actualmente de visión por computadora para transito urbano abordan la detección de accidentes y la optimización del flujo vehicular de forma aislada [5], [7], [10].

El componente innovador de la propuesta radica en integrar las capacidades de detección y clasificación de vehículos y accidentes viales, junto con la notificación de manera eficiente y

oportuna a los servicios de emergencia, todo esto, sobre una misma infraestructura, permitiendo correlacionar información de congestión con eventos de riesgo para mejorar la respuesta ante incidentes.

3. Revisión bibliográfica y estado del arte

A continuación, se presenta la revisión bibliográfica inicial organizada en tres líneas temáticas: (i) detección de accidentes de tránsito mediante visión por computadora y aprendizaje profundo y (ii) sistemas inteligentes de tránsito basados en IoT e IA.

3.1 Detección de accidentes de tránsito mediante visión por computadora y aprendizaje profundo

Los primeros trabajos sobre detección automatizada de accidentes a partir de videos de videovigilancia combinaron cosas como la detección de objetos, seguimiento y análisis de trayectorias para identificar comportamientos anómalos asociados a colisiones. Ghahremannezhad et al. propusieron un marco jerárquico basado en YOLOv4 para la detección de objetos, seguimiento mediante filtro de kalman y algoritmo hungaro, y detección de accidentes mediante el análisis de trayectorias en intersecciones urbanas, reportando resultados viables para aplicaciones en tiempo real [3]. A partir de este trabajo propuesto, estudios recientes han optimizado directamente las arquitecturas de detección de objetos para el dominio específico de accidentes viales. Gao et al. presentaron una red mejorada que emplea YOLOv8, junto con un conjunto de datos propio denominado Acc0D, cuyo objetivo era una reducción del número de parámetros del modelo y una mejora en la extracción de características a diferentes escalas para la detección de accidentes [4].

Siguiendo la misma línea de investigación, Chen et al. propusieron YOLOSED, una veriante de YOLOv8 que integraba un módulo SPD-Conv de submuestreo y un bloque de atención SE. YOLOSED estaba diseñado para mejorar la detección de objetos pequeños y lejanos en escenarios de accidentes captados por cámaras viales, dentro del contexto de aplicaciones de Internet Industrial de las Cosas (IIoT) [5]. De forma similar, Ning et al. desarrollaron TP-YOLOv8, un modelo ligero pensado para su despliegue en dispositivos de borde

instalados en postes de tránsito. TO-YOLOv8 mejoraba el módulo de cuello (neck) de la red para optimizar la relacion entre precisión y consumo computacional [6]. Wu y Lin propusieron un enfoque basado en aprendizaje profundo para la detección de accidentes vehiculares en videos de videovigilancia, evaluando el reconocimiento de daños específicos en la carrocería de los vehículos como ventanas y parabrisas dañados [7].

Más allá de las arquitecturas basadas en YOLO, Singh et al. exploraron el uso de arquitecturas Transformer para la clasificación de segmentos cortos de video de transito en escenas de accidentes y escenas normales. Singh et al. emplearon muestreo adaptativo de fotogramas a partir de mapas de flujo óptico, lo que muestra una tendencia hacia modelos que capturan de forma más robusta la información espacio-temporal del video [8]. Complementariamente, estudios comparativos como el de Geetha et al. han evaluado el desempeño de distintas versiones de YOLO (v8 y v10) específicamente para tareas de detección vehicular, aportando metricas de referencia utiles para seleccionar la arquitectura base del presente proyecto [9].

3.2 Sistemas inteligentes de tránsito basados en IoT e IA

Una segunda línea de investigación aborda la integración de sensores IoT con algoritmos de inteligencia artificial para una gestión integral del tráfico urbano. Saini y Sharma llevaron a cabo una revisión sistemática de 75 estudios publicados entre 2014 y 2023 sobre el moniore inteligente de tráfico vial, pudiendo identificar la gran sinergia entre IoT y algoritmos de inteligencia artificial (IA) como un punto clave de la transformación de los sistemas de transporte inteligente [10]. En la misma línea, Gheorghe y Soica presentaron una revisión sistemática sobre sistemas adaptativos de control de tráfico basados en IA, sensores de IoT y analitica predictiva, reportando reducciones de hasta un 30% en los retrasos de tráfico y mejoras en las métricas de seguridad vial en los estudios analizadas [11]; resultados similares fueron reportados por Mutambik mediante un marco multiagente de gestión adaptativa de tráfico basado en sensores IoT aplicado a un caso de estudio en Londres, con reducciones del 30% en tiempos de viaje y 50% en la congestión de intersecciones principales [12].

Desde la perspectiva de la infraestructura, Dui et al. propusieron un sistema de monitoreo y control de tráfico en tiempo real habilitado por sensores IoT para los sistemas de transporte inteligente, orientado a la recolección y el procesamiento distribuido de datos viales [13]. Ellassy et al., por su parte revisaron el papel de los sistemas de transporte inteligente en la sostenibilidad de las ciudades, destacando la necesidad de integrar sensores IoT, análisis de datos y modelos algoritmos de inteligencia artificial para reducir la congestión y emisiones contaminantes [14]. Finalmente, Jagatheesaperumal et al. exploraron el concepto de Inteligencia Artificial de las Cosas (AIoT) aplicado a ciudades inteligentes, con énfasis en soluciones avanzadas para mejorar la seguridad de transporte urbano [19].

3.3 Síntesis y brecha de investigación

La revisión bibliográfica evidenciada demuestra la variedad de los avances significativos en tanto en materia de la detección de accidentes mediante visión por computador [3]-[9] como en la optimización del tráfico mediantes aprendizaje por refuerzo e IoT [10]-[20]. Sin embargo, se puede identificar claramente la brecha existente: la gran mayoría de los sistemas tratan estos problemas de forma completamente independiente, empleando arquitecturas diferentes, conjuntos de datos y procesos de entrenamiento completamente aislados, lo cual dificulta su despliegue conjunto sobre la misma infraestructura de cámaras y cómputo urbano. Esta brecha constituye la motivación principal del presente proyecto, que propone integrar estas capacidades (la detección y clasificación de vehículos, la detección y clasificación de accidentes de tránsito, y la notificación oportuna a los servicios de emergencia) en un mismo sistema, entrenado sobre un mismo conjunto de datos, el cual permita aprovechar de forma más eficiente los recursos de percepción y procesamiento disponibles en los entornos urbanos.

4. Marco Teórico y Conceptual

4.1 Visión por computadora y detección de objetos

La visión por computadora es el campo de la inteligencia artificial encargado de que los sistemas informáticos interpreten y comprendan información visual a partir de imágenes o

video. En este campo, la detección de objetos consiste en la localización y clasificación de forma simultánea los elementos presentes en una imagen mediante lo que se conoce como cajas delimitadoras (bounding boxes) y etiquetas de clase. La familia de arquitecturas YOLO (You Only Look Once) fórmula la detección de objetos como un único problema de regresión, procesando toda la imagen en una sola pasada de la red, lo que permite alcanzar tiempos de inferencia compatibles con aplicaciones de tiempo real como el análisis de video de transito [3]-[9]. Versiones posteriores de esta arquitectura (YOLOv4 a YOLOv10) han incorporado mejoras en los módulos de extracción de características (backbone), fusión multiescala (neck) y mecanismo de atención, que resultan especialmente relevantes para detectar objetos pequeños o lejanos, como ocurre en escenas de accidentes captadas por cámaras de videovigilancia [4]-[6], [9].

4.2 Aprendizaje profundo y redes convolucionales

El aprendizaje profundo (Deep Learning) es un subcampo del aprendizaje automático basado en redes neuronales de múltiples capas, capaces de aprender representaciones jerárquicas de los datos. Las redes neuronales convolucionales (CNN) constituyen la arquitectura base de la mayoría de los modelos de visión por computadora, aplicando operaciones de convulsión que permiten extraer características espaciales relevantes de una imagen. Para el análisis de video, estas arquitecturas se han combinado con módulos que capturan información temporal, como las redes recurrentes de tipo LSTM y, más recientemente, las arquitecturas Transformer, que permiten modelar relaciones de largo alcance entre fotogramas y han mostrado resultados prometedores en la clasificación de accidentes frente a escenas normales [8].

4.3 Internet de las cosas (IoT) aplicado a sistemas de transporte inteligente

El internet de las cosas (IoT) hace referencia a redes de dispositivos físicos (sensores, cámaras, controladores) interconectados y capaces de recolectar, transmitir y procesar datos en tiempo real. En el contexto del tránsito urbanos, la infraestructura IoT permite capturar de forma distribuida las variables como el flujo vehicular, la velocidad promedio de los vehículos o la ocupación de las vías, y transmitir esta información a plataformas de análisis

basadas en IA para la toma de decisiones, dando lugar al concepto de Inteligencia Artificial de las cosas (AIoT) [10], [13], [19].

4.4 Sistemas de Transporte Inteligente (ITS)

Los sistemas de Transporte Inteligente (ITS - Intelligent Transportation Systems) integran tecnologías de comunicación, sensórica e inteligencia artificial para mejorar la seguridad, la eficiencia y la sostenibilidad de la movilidad. Dentro de este marco se ubican tanto los sistemas de gestión adaptativa de tráfico, como los sistemas de detección temprana de incidentes, siendo este último especialmente relevante para la reducción en el tiempo de respuesta de los servicios de emergencia ante un accidente [11], [12], [14].

4.5 Métricas de evaluación de modelos de detección de objetos

Para llevar a cabo la evaluación de los modelos de detección de accidentes propuestos en la literatura y del modelo a desarrollar en el presente proyecto, se emplean métricas estándar del campo de la visión por computadora. La precisión (precision) indica la proporción de detecciones correctas frente al total de detecciones realizadas por el modelo. La exhaustividad (recall) indica la proporción de eventos reales que fueron detectados correctamente. El F1-score es la media armónica entre la precisión y la exhaustividad. Y, la precisión promedio media (mAP - mean Average Precision) resume el desempeño del modelo considerando diferentes umbralesde solapamiento entre cajas delimitadoras predichas y reales (IoU Intersection over Union) [4]-[6], [9]. Estas métricas será empleadas en las siguientes fases del proyecto para comparar el desempeño del modelo entrenado con los trabajos relacionados,

Referencias bibliográficas

[1] World Health Organization, Global Status Report on Road Safety 2023. Geneva, Switzerland: WHO, 2023.

[2] A. Haydari and Y. Yılmaz, "Deep reinforcement learning for intelligent transportation systems: A survey," IEEE Trans. Intell. Transp. Syst., vol. 23, no. 1, pp. 11–32, Jan. 2022.

[3] H. Ghahremannezhad, H. Shi, and C. Liu, "Real-time accident detection in traffic surveillance using deep learning," in Proc. 2022 IEEE Int. Conf. Imaging Systems and Techniques (IST), 2022, pp. 1–6.

[4] G. Gao, D. Deng, G. Shi, Y. Guo, and Z. Ning, "Research on methodology of intelligent traffic accident detection based on enhanced YOLOv8 algorithm," in Proc. 2024 Int. Conf. Generative Artificial Intelligence and Information Security (GAIIS 2024), Kuala Lumpur, Malaysia, May 2024, pp. 340–348.

[5] J. Chen, Y. Jin, X. Chen, B. Sun, and X. Jin, "Surveillance-based road accident detection method using improved YOLOv8 for IIoT applications," in Proc. 2024 IEEE/CIC Int. Conf. Communications in China (ICCC), 2024, pp. 1413–1418.

[6] Z. Ning, T. Zhang, X. Li, et al., "TP-YOLOv8: A lightweight and accurate model for traffic accident recognition," J. Supercomput., vol. 81, art. 622, 2025.

[7] X. Wu and T. Li, "A deep learning-based car accident detection approach in video-based traffic surveillance," J. Opt., vol. 53, pp. 3383–3391, 2024.

[8] T. Singh, P. Chakraborty, and L. T. Truong, "Surveillance video-based traffic accident detection using transformer architecture," arXiv preprint arXiv:2512.11350, 2025.

[9] A. S. Geetha, M. A. R. Alif, M. Hussain, and P. Allen, "Comparative analysis of YOLOv8 and YOLOv10 in vehicle detection: Performance metrics and model efficacy," Vehicles, vol. 6, no. 3, pp. 1364–1382, 2024.

[10] K. Saini and S. Sharma, "Smart road traffic monitoring: Unveiling the synergy of IoT and AI for enhanced urban mobility," ACM Comput. Surv., vol. 57, no. 11, pp. 1–45, 2025.

[11] C. Gheorghe and A. Soica, "Revolutionizing urban mobility: A systematic review of AI, IoT, and predictive analytics in adaptive traffic control systems for road networks," Electronics, vol. 14, no. 4, p. 719, 2025.

[12] I. Mutambik, "IoT-enabled adaptive traffic management: A multiagent framework for urban mobility optimization," Sensors, vol. 25, no. 13, p. 4126, 2025.

[13] H. Dui, S. Zhang, M. Liu, X. Dong, and G. Bai, "IoT-enabled real-time traffic monitoring and control management for intelligent transportation systems," IEEE Internet Things J., vol. 11, no. 9, pp. 15842–15854, 2024.

[14] M. Elassy, M. Al-Hattab, M. Takruri, and S. Badawi, "Intelligent transportation systems for sustainable smart cities," Transp. Eng., vol. 16, art. 100252, 2024.

[15] T. Yang and W. Fan, "Enhancing robustness of deep reinforcement learning based adaptive traffic signal controllers in mixed traffic environments through data fusion and multi-discrete actions," IEEE Trans. Intell. Transp. Syst., 2024.

[16] H. Gu, S. Wang, X. Ma, D. Jia, G. Mao, E. G. Lim, and C. P. R. Wong, "Large-scale traffic signal control using constrained network partition and adaptive deep reinforcement learning," IEEE Trans. Intell. Transp. Syst., vol. 25, pp. 7619–7632, 2024.

[17] M. Li, X. Pan, C. Liu, and Z. Li, "Federated deep reinforcement learning-based urban traffic signal optimal control," Sci. Rep., vol. 15, art. 11724, 2025.

[18] H. Wang, M. Zhu, W. Hong, C. Wang, W. Li, G. Tao, and Y. Wang, "Network-wide traffic signal control using bilinear system modeling and adaptive optimization," IEEE Trans. Intell. Transp. Syst., vol. 24, no. 1, pp. 79–91, Jan. 2023.

[19] S. K. Jagatheesaperumal, S. E. Bibri, J. Huang, J. Rajapandian, and B. Parthiban, "Artificial intelligence of things for smart cities: Advanced solutions for enhancing transportation safety," Comput. Urban Sci., vol. 4, no. 1, p. 10, 2024.

[20] S.-W. Chiou, "A cooperative agent-based traffic signal control for vehicular networks under stochastic flow," IEEE Trans. Veh. Technol., vol. 72, no. 10, pp. 12592–12601, Oct. 2023.